

Sistema automático de clasificación de calidad y tamaño de frutas mediante visión por computador

Johan Stiven Guzmán, Karold Lizeth Mejia Orozco, Adri Jhoanny Martínez Murillo

Departamento de Computación y Sistemas Inteligentes, Universidad ICESI

Repositorio: <https://github.com/karoldmejia/fruits-classificator> - **Video:** <https://youtu.be/Wjoka48gSRo>

Resumen: Se presentan el diseño, la implementación y la evaluación de un sistema automático de clasificación de calidad y tamaño de frutas basado en visión por computador, siguiendo la metodología CRISP-DM. A partir de un conjunto de datos de 36.848 muestras correspondientes a seis tipos de fruta, se extrajeron nueve características geométricas y cromáticas en el espacio de color HSV. Se entrenaron y compararon tres arquitecturas: Máquinas de Vectores de Soporte (SVM), Gradient Boosting Extremo (XGBoost) y una Red Neuronal Convolucional (CNN). Los resultados demuestran que la CNN obtiene el mejor desempeño en clasificación de calidad (F1-Macro = 0,9497; MCC = 0,9229), mientras que XGBoost supera a los demás modelos en clasificación de tamaño (F1-Macro = 0,9813; MCC = 0,9721). La estrategia óptima consiste en una arquitectura híbrida que combina ambos modelos según la naturaleza de cada tarea. El sistema incluye una interfaz gráfica funcional implementada en Streamlit y es viable para su despliegue en entornos agroindustriales reales.

Palabras claves: clasificación de frutas, visión por computador, SVM, XGBoost, red neuronal convolucional, CRISP-DM, calidad, tamaño.

I. INTRODUCCIÓN

En mercados y agroindustrias, la clasificación manual de frutas según calidad y tamaño es un proceso lento, subjetivo y propenso a errores. Un inspector humano puede revisar entre 400 y 800 unidades por hora, mientras que un sistema automático puede superar las 10.000 unidades en el mismo intervalo. Según la FAO, aproximadamente el 14 % de los alimentos producidos a nivel global se pierde antes de llegar al consumidor, en gran parte por deficiencias en las etapas de clasificación y empaque [1]. En Colombia, el Ministerio de Agricultura reporta que entre el 30 % y el 40 % de la producción hortofrutícola se pierde antes de llegar al consumidor [2]. La visión por computador ofrece una alternativa objetiva, reproducible y escalable para automatizar esta clasificación.

Este artículo presenta el diseño, la implementación y la evaluación de un sistema automático de clasificación de calidad y tamaño de frutas, desarrollado como proyecto final del curso Algoritmos y Programación III (Semestre 2026-1) de la Universidad ICESI bajo la metodología CRISP-DM. Las contribuciones principales son: (i) un pipeline de preprocesamiento híbrido que combina YOLOv8 con métodos clásicos de segmentación; (ii) la generación automática de etiquetas de tamaño mediante análisis de percentiles; (iii) la comparación experimental entre SVM, XGBoost y CNN sobre 36.848 muestras; y (iv) una arquitectura híbrida que selecciona el modelo óptimo según la tarea.

El artículo se organiza de la siguiente manera: la Sección II describe los fundamentos teóricos; la Sección III detalla la metodología CRISP-DM aplicada; la Sección IV presenta los resultados experimentales; la Sección V analiza los resultados; la Sección VI aborda las implicaciones éticas e impactos de la solución; y la Sección VII presenta las conclusiones.

II. FUNDAMENTOS TEÓRICOS

A. Formulación matemática del problema

Sea el vector de características de la i -ésima imagen el siguiente conjunto de nueve descriptores geométricos y cromáticos, donde los primeros tres son medidas de forma y los seis restantes corresponden a estadísticas del espacio HSV:

$$x_i = [area_{px}, aspect_ratio, coverage_ratio, \mu_h, \mu_s, \mu_v, \sigma_h, \sigma_s, \sigma_v]^T \in R^9 \quad (1)$$

El problema de clasificación de calidad se formula como encontrar una función $f_{calidad} : R^9 \rightarrow \{\text{good, regular, bad}\}$ y el de tamaño como $f_{tamaño} : R^9 \rightarrow \{\text{pequeño, mediano, grande}\}$, que minimicen el error de clasificación sobre un conjunto de prueba independiente, medido mediante el F1-Score Macro:

$$F1_{macro} = \frac{1}{|C|} \sum_{c \in C} \frac{2P_c R_c}{P_c + R_c} \quad (2)$$

donde C es el conjunto de clases, P_c es la precisión de la clase c y R_c es el recall de la clase c . Esta métrica trata todas las clases por igual, siendo adecuada para conjuntos con desbalance de clases. Este es un problema

complejo de ingeniería porque: las clases de calidad no son linealmente separables en el espacio HSV usando únicamente descriptores estadísticos globales; el dataset presenta desbalance crítico ($IR > 3$) en cuatro de seis frutas; las imágenes provienen de fuentes heterogéneas con resoluciones distintas; y los defectos de calidad son fenómenos locales de textura no capturables por descriptores globales.

B. Desbalance de clases e Imbalance Ratio

El Imbalance Ratio (IR) cuantifica el grado de desbalance entre categorías. Se define como:

$$IR = \frac{N_{max}}{N_{min}} \quad (3)$$

donde N_{max} y N_{min} corresponden al número de muestras de la clase mayoritaria y minoritaria, respectivamente. Un $IR > 3$ indica desbalance crítico: la clase minoritaria contiene menos de un tercio de las muestras de la mayoritaria, generando clasificadores sesgados hacia las clases mayoritarias e inútiles en la práctica.

C. Generación automática de etiquetas de tamaño

El conjunto de datos original no incluía etiquetas de tamaño. Estas se generaron automáticamente calculando primero el área normalizada de cada fruta:

$$\text{Área}_{Norm} = \frac{\text{Área}_{fruta}}{\text{Área}_{imagen}} \quad (4)$$

Posteriormente, para cada tipo de fruta se calcularon los percentiles P_{33} y P_{66} de esta distribución. Las etiquetas se asignaron de la siguiente manera: pequeño si $\text{Área}_{Norm} < P_{33}$; mediano si $P_{33} \leq \text{Área}_{Norm} \leq P_{66}$; y grande si $\text{Área}_{Norm} > P_{66}$. Este procedimiento adapta los umbrales a las características propias de cada especie.

D. Máquinas de Vectores de Soporte (SVM)

El SVM con kernel RBF proyecta el espacio de características a una dimensión superior donde las clases son separables. La función de decisión para clasificación multiclase (one-vs-one) es:

$$f(x) = \text{sgn} \left(\sum_{i=1}^n \alpha_i y_i K(x_i, x) + b \right) \quad (5)$$

donde el kernel radial $K(x_i, x)$ mide la similitud entre vectores, y el parámetro γ controla el radio de influencia de cada vector de soporte:

$$K(x_i, x) = \exp(-\gamma \|x_i - x\|^2)$$

El parámetro C regula el balance entre el margen de separación y los errores de clasificación. Se incluyó `class_weight="balanced"` para compensar el desbalance residual tras el `augmentation`.

E. XGBoost

XGBoost construye un ensamble de árboles de decisión mediante gradient boosting. En cada iteración t , se añade un árbol que minimiza la función objetivo regularizada [3]:

$$L^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t) \quad (6)$$

donde l es la función de pérdida (log-loss multiclase) y $\Omega(f_t) = \gamma T + \frac{1}{2} \lambda \|w\|^2$ es el término de regularización con T hojas y pesos w , que controla la complejidad del árbol y previene el sobreajuste.

F. Red Neuronal Convolutiva (CNN)

La CNN extrae características jerárquicas directamente de los píxeles mediante operaciones de convolución. Una capa convolutiva en la capa l computa:

$$h^{(l)} = \text{ReLU}(W^{(l)} * h^{(l-1)} + b^{(l)}) \quad (7)$$

donde $W^{(l)}$ son los filtros aprendibles de la capa l y $\text{ReLU}(x) = \max(0, x)$ es la función de activación no lineal.

Las probabilidades obtenidas mediante la función Softmax se utilizan para calcular la entropía cruzada categórica dispersa, la cual mide la discrepancia entre la distribución predicha por la red y las etiquetas reales del conjunto de entrenamiento.

$$p(y = k|x) = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}$$

La función de pérdida utilizada es la entropía cruzada categórica dispersa [4]:

$$L_{CE} = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K y_{ik} \log \log(\hat{y}_{ik}) \quad (8)$$

donde $p(y_i | x_i)$ es la distribución softmax de salida de la red para la clase correcta y_i dado el tensor de entrada x_i .

G. Métricas de evaluación


Dado el desbalance de clases, se emplearon métricas robustas. El Coeficiente de Correlación de Matthews (MCC) evalúa el acuerdo entre predicciones y etiquetas reales tomando valores en $[-1, 1]$:

$$MCC = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP+FP)(TP+FN)(TN+FP)(TN+FN)}} \quad (9)$$

El MCC penaliza por igual los errores en clases minoritarias y mayoritarias, siendo más informativo que la exactitud global ante desbalance. El Coeficiente Kappa de Cohen κ cuantifica el acuerdo corrigiendo el azar ($\kappa > 0,80$ indica acuerdo casi perfecto). El AUC-ROC Macro evalúa la capacidad discriminativa bajo distintos umbrales de decisión, promediando el AUC de cada clase.

III. METODOLOGÍA

Se adoptó la metodología CRISP-DM adaptada a las fases del proyecto. El repositorio del código sigue la misma estructura, con un notebook dedicado a cada fase.



A. Comprensión del negocio

Se definieron dos tareas de clasificación supervisada multiclase: calidad ({good, regular, bad}) y tamaño ({pequeño, mediano, grande}). Los criterios de éxito técnico se establecieron en $F1\text{-Macro} \geq 0,93$ para calidad y $\geq 0,95$ para tamaño. Se identificaron diez riesgos del proyecto (desbalance de clases, ruido de iluminación,

heterogeneidad de resoluciones) con sus estrategias de mitigación correspondientes.

B. Comprensión de los datos

Se utilizó el conjunto de datos Fruit Quality Classification de Kaggle [5], complementado con imágenes propias recolectadas en plazas de mercado. El análisis exploratorio (EDA) reveló seis tipos de fruta (manzana, banano, lima, naranja, granada y guayaba) con desbalance crítico ($IR > 3$) en cuatro de ellas. El caso más severo corresponde a las granadas ($IR = 14,40$), donde la clase regular representa el 4,4 % de las muestras. El EDA también demostró que las clases de calidad no son linealmente separables en el espacio HSV mediante descriptores estadísticos globales, justificando el uso de modelos no lineales y redes convolucionales.

C. Preparación de los datos

El pipeline de preprocesamiento comprendió cinco etapas. Primero, la detección y extracción de frutas se realizó mediante una estrategia híbrida: YOLOv8 para detectar automáticamente frutas con clases disponibles (manzanas, naranjas, bananos), y métodos de visión clásica (segmentación en espacio HSV, detección de contornos y umbralización) como mecanismo de respaldo. Se aplicó Non-Maximum Suppression (NMS) para eliminar detecciones duplicadas.

Segundo, los recortes inválidos fueron descartados automáticamente si eran demasiado pequeños, presentaban escasa variabilidad de color o carecían de textura visual. Tercero, todas las imágenes fueron normalizadas a 224×224 píxeles para almacenamiento y redimensionadas a 64×64 píxeles durante la carga por lotes en la CNN, empleando un generador de datos con lazy loading. Cuarto, se extrajeron nueve características (Ec. 1). Quinto, el desbalance ($IR > 3$) se trató mediante data augmentation focalizado en clases minoritarias: rotaciones aleatorias, volteos horizontales y verticales, variaciones de brillo y contraste, ruido gaussiano y pequeños desplazamientos. El dataset final quedó compuesto por 36.848 muestras con 24 atributos.

TABLA I. DISTRIBUCIÓN DE CLASES ANTES Y DESPUÉS DEL BALANCEO

Fruta	IR orig.	Bad	Regular	Good
Granada	14,40	7.545	De 524 a 6.231	3.808
Naranja	5,59	2.156	De 386 a 1.547	2.159
Manzana	3,20	1.180	De 561 a 1.235	1.782

Limón	3,10	892	De 438 a 920	1.357
Banano	1,57	712	-	1.118
Guayaba	1,80	618	-	1.113

Nota: Las celdas en regular indican el incremento por data augmentation en clases minoritarias ($IR > 3$).

D. Modelado

Se entrenaron tres modelos para cada tarea con una partición estratificada de 80 % entrenamiento (29.478 muestras) y 20 % prueba (7.370 muestras). Para el SVM se construyó un pipeline con StandardScaler y SVC(kernel='rbf', class_weight='balanced'). La optimización de hiperparámetros mediante RandomizedSearchCV (3-fold, F1-Macro) identificó $C = 10$ y $\gamma = 1$ para ambas tareas, alcanzando F1-Macro de validación cruzada de 0,8671 (calidad) y 0,9208 (tamaño). La validación cruzada inicial con parámetros por defecto arrojó F1-Macro = 0,8244.

Para XGBoost, la búsqueda con RandomizedSearchCV exploró 648 combinaciones ($n_estimators \in \{100, 200, 300\}$, $max_depth \in \{3, 5, 7, 9\}$, $learning_rate \in \{0,01; 0,05; 0,1; 0,3\}$, $subsample$ y $colsample_bytree \in \{0,6; 0,8; 1,0\}$, $min_child_weight \in \{1, 3, 5\}$). El F1-Macro de validación cruzada inicial con parámetros por defecto fue 0,9363 (calidad) y 0,9773 (tamaño).

La arquitectura CNN consta de cuatro bloques convolucionales con 32, 64, 128 y 256 filtros de 3×3 , seguidos de BatchNormalization y MaxPooling 2×2 . El bloque de clasificación incluye Flatten, Dropout(0,5), Dense(256, ReLU), Dropout(0,3), Dense(128, ReLU) y capa softmax de salida. El entrenamiento empleó optimizador Adam ($\alpha_0 = 0,001$), EarlyStopping (patience = 3), ReduceLROnPlateau (factor = 0,5, patience = 2) y ModelCheckpoint. El modelo de calidad convergió en la época 9 y el de tamaño en la época 14.

E. Evaluación

Cada modelo fue evaluado sobre el conjunto de prueba independiente usando F1-Score Macro, MCC, Coeficiente Kappa de Cohen, Balanced Accuracy y AUC-ROC Macro (Ec. 2, 9). Se construyó una matriz de decisión ponderada (F1-Macro: 35 %, MCC: 25 %, Kappa: 20 %, Balanced Accuracy: 20 %) para seleccionar el modelo óptimo por tarea.

F. Despliegue

Los modelos seleccionados fueron integrados en una interfaz gráfica implementada con Streamlit, que permite cargar una imagen o capturarla en tiempo real mediante la

cámara web, y obtener las predicciones de calidad y tamaño en menos de un segundo. El sistema incorpora indicadores de confianza para cada predicción y es compatible con despliegue en la nube o en hardware embebido.

IV. RESULTADOS

La Tabla II presenta los resultados del clasificador base (Dummy), que asigna siempre la clase mayoritaria. Con F1-Macro = 0,1926 y MCC = 0 en calidad, este modelo establece el umbral mínimo que cualquier modelo real debe superar.

TABLA II. RESULTADOS DEL DUMMY CLASSIFIER (BASELINE)

Tarea	F1-Macro	MCC	Kappa	Bal. Acc.
Calidad	0,1926	0,0000	0,0000	0,3333
Tamaño	0,1667	0,0000	0,0000	0,3333

La Tabla III presenta los resultados completos de los tres modelos sobre el conjunto de prueba para la tarea de clasificación de calidad.

TABLA III. RESULTADOS COMPARATIVOS CLASIFICACIÓN DE CALIDAD

Modelo	F1-Macro	MCC	Kappa	Bal. Acc.	AUC
SVM	0,9319	0,8979	0,8978	0,9300	>0,97
XGBoost	0,9494	0,9219	0,9218	0,9490	>0,97
CNN	0,9497	0,9229	0,9229	0,9493	>0,97

Nota: Negrita indica el mejor resultado por métrica. Accuracy global: SVM $\approx 93,0$ %, XGBoost $\approx 94,9$ %, CNN $\approx 94,9$ %.

La Tabla IV presenta los resultados para la tarea de clasificación de tamaño.

TABLA IV. RESULTADOS COMPARATIVOS CLASIFICACIÓN DE TAMAÑO

Modelo	F1-Macro	MCC	Kappa	Bal. Acc.	AUC
SVM	0,9590	0,9389	0,9387	0,9588	>0,98
XGBoost	0,9813	0,9721	0,9720	0,9812	>0,99
CNN	0,9181	>0,80	>0,80	0,9175	0,9879

Nota: Accuracy global: SVM $\approx$ 96,0 %, XGBoost $\approx$ 98,1 %, CNN $\approx$ 92,1 %.

La Tabla V resume los resultados de la matriz de decisión ponderada para la selección del modelo óptimo por tarea.

TABLA V. MATRIZ DE DECISIÓN PONDERADA SELECCIÓN DEL MODELO FINAL

Modelo	Score Calidad	Score Tamaño	Score Global
CNN	0,9494	0,8878	0,9186
SVM	0,9220	0,9429	0,9325
XGBoost	0,9490	0,9651	0,9571

Nota ponderada: F1-Macro: 35 %, MCC: 25 %, Kappa: 20 %, Balanced Accuracy: 20 %.

V. ANÁLISIS DE RESULTADOS

A. Clasificación de calidad

Los tres modelos superan ampliamente al baseline con mejoras absolutas superiores a 73 puntos porcentuales en F1-Macro (de 0,1926 a $\geq$ 0,9319), lo que demuestra que el pipeline de ingeniería de características aporta valor discriminativo real. CNN y XGBoost obtienen desempeños prácticamente equivalentes (diferencia de solo 0,0003 en F1-Macro), pero las curvas de aprendizaje revelan una diferencia cualitativa importante: XGBoost mantiene F1-Macro = 1,0 en entrenamiento durante todo el proceso (sobreajuste estructural), mientras que la CNN mantiene una brecha reducida entre entrenamiento y validación, indicando mejor capacidad de generalización ante variaciones de iluminación no vistas. En consecuencia, la CNN es la arquitectura más adecuada para calidad en un entorno de producción real.

B. Clasificación de tamaño

XGBoost domina con F1-Macro = 0,9813 y MCC = 0,9721, representando una mejora de 2,23 puntos porcentuales sobre SVM y 6,32 sobre CNN. Esta superioridad se explica por la naturaleza del problema: las características geométricas *area_px*, *aspect_ratio* y *coverage_ratio* representan directamente el tamaño de la fruta, simplificando la tarea hasta la saturación de la curva de aprendizaje alrededor de la época 25. La CNN, al inferir la escala implícitamente desde el tensor de imagen en bruto, es más sensible a variaciones de perspectiva y encuadre. Los errores de la CNN se concentran en la clase mediano (F1 = 0,89), exhibiendo el solapamiento en ambas fronteras típico de las clases intermedias en problemas de clasificación ordinal discretizada.

C. Generalización y sobreajuste

Las curvas ROC confirman la robustez de los tres modelos: AUC-ROC Macro $>$ 0,97 en todas las combinaciones modelo-tarea, indicando excelente capacidad discriminativa. Las curvas de aprendizaje muestran que SVM y CNN no saturan completamente, sugiriendo que podrían beneficiarse de más datos de entrenamiento, mientras que XGBoost para tamaño alcanzó el límite de información del conjunto de características actual. En comparación con la literatura, los resultados son competitivos: estudios similares de clasificación de frutas con CNN reportan F1-Macro entre 0,91 y 0,97 para conjuntos de datos comparables [6], [7]; XGBoost para tamaño con características geométricas supera los resultados análogos que reportan AUC $\approx$ 0,96 [8].

D. Selección del modelo final

La matriz de decisión ponderada (Tabla V) confirma que XGBoost obtiene el mejor score global (0,9571). No obstante, el análisis por tarea determina la estrategia óptima: CNN para calidad y XGBoost para tamaño. Esta arquitectura híbrida maximiza el desempeño global del sistema, aprovechando la capacidad de la CNN para aprender patrones complejos de textura y la eficiencia de XGBoost para variables geométricas bien definidas. El pipeline de preprocesamiento combinado (YOLOv8, segmentación clásica, NMS y data augmentation focalizado) fue determinante para construir un dataset balanceado y representativo, siendo fundamental para el alto desempeño obtenido por todos los modelos.

VI. ANÁLISIS ÉTICO E IMPACTO DE LA SOLUCIÓN

A. Identificación y análisis de dilemas éticos (PII)

A lo largo del desarrollo del proyecto se identificaron seis situaciones con implicaciones éticas directas. La Tabla VI presenta cada situación, el riesgo asociado, el principio del código de ética profesional involucrado y las medidas de mitigación adoptadas.

TABLA VI. DECISIONES ÉTICAS DEL PROYECTO Y MEDIDAS ADOPTADAS

Situación ética	Riesgo	Código de ética	Medida adoptada
Recolección de imágenes en plazas de mercado	Captura accidental de personas identificables	ACM 1.6, Privacidad	Revisión y eliminación de imágenes con personas antes de incorporarlas al dataset

Sesgos en el dataset de entrenamiento	Modelo que falla en condiciones distintas a las de entrenamiento	IEEE 6, Justicia y equidad	Complemento con imágenes diversas propias; reporte explícito de limitaciones del modelo
Uso en decisiones comerciales	Pérdidas económicas por errores del modelo	IEEE 1, Responsabilidad profesional	Reporte de tasas de error por clase; supervisión humana recomendada en casos límite
Desplazamiento de mano de obra	Reducción de empleos de clasificadores manuales	IEEE 1, Impacto social	Sistema concebido como apoyo, no reemplazo total; propuesta de reentrenamiento laboral
Opacidad del modelo CNN	Decisiones difíciles de explicar a operarios (caja negra)	IEEE 3, Honestidad y transparencia	Métricas de confianza en la GUI; documentación del comportamiento por clase
Uso del dataset de Kaggle (terceros)	Posible violación de derechos de uso	ACM 1.5, Propiedad intelectual	Citación explícita de la fuente; verificación de licencia de uso del dataset público

Económico	Reducción del desperdicio poscosecha (hasta 30 % según la FAO); reducción de costos operativos; acceso a certificaciones de calidad internacional	Costo de implementación de infraestructura; riesgo de pérdidas por errores del modelo	Reportar tasas de error; auditoría humana periódica; evaluar ROI antes del despliegue
Ambiental	Reducción del desperdicio alimentario disminuye emisiones de CO ₂ de toda la cadena productiva (riego, fertilizantes, transporte)	Entrenamiento de modelos deep learning con alto consumo energético; huella de hardware	EarlyStopping para reducir épocas de entrenamiento; modelos eficientes; uso de hardware compartido con energías renovables
Global	Solución replicable a cualquier cultivo frutal; pipelines adaptables a diferentes contextos culturales y regulatorios	Incompatibilidades regulatorias por país; sesgo hacia frutas tropicales del hemisferio sur	Verificar compatibilidad con normativas locales; ampliar dataset con frutas de otras regiones geográficas

B. Impactos globales, sociales, ambientales y económicos (PI2)

La Tabla VII presenta la matriz de impactos de la solución en las cuatro dimensiones requeridas, con estrategias de mitigación para los impactos negativos identificados.

TABLA VII. MATRIZ DE IMPACTOS DE LA SOLUCIÓN

Dimensión	Impacto positivo	Impacto negativo (riesgo)	Estrategia de mitigación
Social	Permite a pequeños productores acceder a mercados de exportación (UE, EE.UU., Japón) con estándares estrictos; reduce la brecha tecnológica	Desplazamiento potencial de clasificadores manuales	Sistema diseñado como herramienta de apoyo; programas de reentrenamiento laboral

VII. CONCLUSIONES Y TRABAJO FUTURO

Se desarrolló exitosamente un sistema automático de clasificación de calidad y tamaño de frutas siguiendo la metodología CRISP-DM. Los principales hallazgos son los siguientes:

1) La CNN es el modelo más adecuado para la clasificación de calidad (F1-Macro = 0,9497; MCC = 0,9229), gracias a su capacidad de extraer automáticamente patrones complejos de textura, manchas y defectos superficiales directamente desde las imágenes, superando las limitaciones de los descriptores estadísticos globales.

2) XGBoost es claramente superior para la clasificación de tamaño (F1-Macro = 0,9813; MCC = 0,9721), dado que las características geométricas (área y cobertura) representan directamente la variable objetivo, simplificando la tarea hasta el punto de saturación de la curva de aprendizaje.

3) La estrategia híbrida (CNN para calidad y XGBoost para tamaño) maximiza el desempeño global del sistema,

aprovechando las fortalezas específicas de cada arquitectura según la naturaleza del problema.

4) El pipeline de preprocesamiento (YOLOv8, métodos clásicos, NMS y data augmentation focalizado) fue determinante para construir un dataset balanceado y representativo, siendo fundamental para el alto desempeño de todos los modelos.

5) Todos los modelos superaron ampliamente el baseline en más de 73 puntos porcentuales de F1-Macro, demostrando que las características extraídas aportan valor discriminativo real.

Como trabajo futuro se propone: (i) incorporar Grad-CAM para mejorar la transparencia del modelo CNN; (ii) explorar MobileNetV3 para despliegue en dispositivos embebidos; (iii) implementar transfer learning desde modelos preentrenados en ImageNet; (iv) ampliar el sistema a video en tiempo real para líneas de empaque industriales; y (v) extender el dataset con frutas de otras regiones para mejorar la generalización geográfica del modelo.

. REFERENCIAS

- [1] Food and Agriculture Organization of the United Nations, "The State of Food and Agriculture 2019. Moving Forward on Food Loss and Waste Reduction," FAO, Rome, Italy, 2019. [Online]. Available: <https://www.fao.org/3/ca6030en/ca6030en.pdf>
- [2] Ministerio de Agricultura y Desarrollo Rural de Colombia, "Informe de Gestión Sectorial 2022," Bogotá, Colombia, 2022.
- [3] T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," in Proc. 22nd ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining, San Francisco, CA, USA, 2016, pp. 785–794. doi: 10.1145/2939672.2939785
- [4] I. Goodfellow, Y. Bengio, and A. Courville, Deep Learning. Cambridge, MA: MIT Press, 2016.
- [5] R. Park, "Fruit Quality Classification," Kaggle Dataset, 2023. [Online]. Available: <https://www.kaggle.com/datasets/ryandpark/fruit-quality-classification>
- [6] N. Khanramaki, S. K. Asli-Ardeh, and B. Kozegar, "Citrus pests classification using an ensemble of deep learning models," Computers and Electronics in Agriculture, vol. 186, p. 106174, 2021. doi: 10.1016/j.compag.2021.106174
- [7] A. Bhatt, P. Ganatra, and K. Kotecha, "Fruit freshness grading using deep learning," Scientific Reports, vol. 13, no. 1, p. 9218, 2023. doi: 10.1038/s41598-023-36043-9
- [8] S. M. Khatami et al., "Machine learning-based fruit quality assessment with geometric and color features," Computers and Electronics in Agriculture, vol. 197, p. 106990, 2022. doi: 10.1016/j.compag.2022.106990
- [9] C. Shearer, "The CRISP-DM Model: The New Blueprint for Data Mining," Journal of Data Warehousing, vol. 5, no. 4, pp. 13–22, 2000.
- [10] Association for Computing Machinery, "ACM Code of Ethics and Professional Conduct," ACM, New York, NY, USA, 2018. [Online]. Available: <https://www.acm.org/code-of-ethics>
- [11] IEEE, "IEEE Code of Ethics," IEEE, Piscataway, NJ, USA, 2020. [Online]. Available: <https://www.ieee.org/about/corporate/governance/p7-8.html>
- [12] G. Jocher et al., "Ultralytics YOLOv8," GitHub repository, 2023. [Online]. Available: <https://github.com/ultralytics/ultralytics>